

正态分布在现实数据分析中的应用

——基于中国成年人身高数据的案例分析

《概率论与数理统计》课程论文报告

作者：_____ 学号：_____

日期：_____

为什么研究"身高与正态分布"?

身高是最常见的连续型人体测量变量之一。在合理划分研究总体后，它的分布往往呈现近似钟形——这正是正态分布登场的现实土壤。

- 1 身高是典型连续型变量，可测量、可比较、可重复；
- 2 控制年龄、性别后，身高分布常呈近似钟形，适合用正态模型描述；
- 3 正态分布仅需 μ 、 σ 两个参数即可刻画"中心"与"离散"，并支撑标准化、区间覆盖与相对位置判断。

核心问题：现实中的身高数据，究竟在多大程度上可以用正态分布近似描述？ [2][3][10]

正态分布的基本理论

μ 描述中心位置, σ 描述波动程度, Z 描述个体相对位置。

$$X \sim N(\mu, \sigma^2)$$

$$f(x) = \frac{1}{\sigma\sqrt{2\pi}} \exp\left(-\frac{(x-\mu)^2}{2\sigma^2}\right) \quad Z = \frac{X-\mu}{\sigma}$$

$$E(X) = \mu \quad \text{Var}(X) = \sigma^2$$

3 σ 原则 (正态总体的经典区间覆盖)

$$\pm 1\sigma \rightarrow 68.27\% \quad \pm 2\sigma \rightarrow 95.45\% \quad \pm 3\sigma \rightarrow 99.73\%$$

数据来源与研究总体

数据从哪里来？研究对象是谁？

- 数据来源：2011 年 CHNS（中国健康与营养调查）
- 正式研究总体：2011 年、20~24 岁成年人
- 分析方式：男性、女性分别进行
- 正式样本：473 人（男性 220 / 女性 253）

CHNS 为抽样样本，结论不能直接表述为“中国所有成年人”的总体规律。



数据清洗与样本形成

518

条原始记录

-45

条身高缺失

473

条有效记录

220 / 253

男性 / 女性

518 → 473 → 男 220 / 女 253

身高 < 100 cm: 0 条; 身高 > 220 cm: 0 条。

没有任何记录因极端值被删除; 女性最低值 134.9 cm 按原始观测保留。

最终样本如何得到, 且未为迎合正态而人为删数据。

描述统计——男女身高的基本特征

表 5-1 2011 年 CHNS 20 ~ 24 岁成年人身高描述统计量

指标	男性	女性
样本量 n	220	253
均值 (cm)	171.5614	159.5917
中位数 (cm)	172.0000	160.0000
标准差 (cm)	6.8218	6.0802
偏度	0.0107	-0.3614
超额峰度	-0.0150	0.5907

男性 均值 ± 标准差
171.56 ± 6.82 cm

女性 均值 ± 标准差
159.59 ± 6.08 cm

男性样本中心位置更高；女性样本标准差略小。两组分布形态总体接近钟形，但并非完全理想正态。

直方图——实际分布长什么样？




图 5-1 男性身高直方图及理论正态曲线




图 5-2 女性身高直方图及理论正态曲线

整体呈单峰、近似钟形；男性样本与正态形态较为接近；
女性样本存在轻度偏离，但整体形态仍具较明显的正态特征。
(注意"近似"措辞：不表述为"完全服从正态分布".)

Q-Q 图 + Shapiro-Wilk 检验




图 5-3 男性身高 Q-Q 图




图 5-4 女性身高 Q-Q 图

性别	n	W	p
男性	220	0.992062	0.2799
女性	253	0.987611	0.0281

男性: $p=0.2799 > 0.05 \rightarrow$ 在 5% 水平下不能拒绝正态性原假设。

女性: $p=0.0281 < 0.05 \rightarrow$ 在 5% 水平下拒绝正态性原假设, 存在统计可检测偏离。

强调: $P > 0.05$ 不等于证明正态; $P < 0.05$ 也不等于正态模型完全不能使用。

3 σ 原则——理论与现实有多接近？

范围	理论值	男性	女性
$\pm 1\sigma$	68.27%	70.00%	68.77%
$\pm 2\sigma$	95.45%	95.91%	96.05%
$\pm 3\sigma$	99.73%	100.00%	99.60%

两组样本的实际覆盖率与正态分布理论值总体接近；因此即使女性样本经 Shapiro-Wilk 检验发现统计显著偏离，其整体尺度与区间覆盖特征仍具有明显的正态近似价值。

注意：不得写“女性也通过了正态性检验”，也不得写“3 σ 证明了女性服从正态”——只能说覆盖率与理论值较为接近。

这说明了什么？——价值与局限

实际价值

- ✓ 描述总体特征：用少量参数概括分布中心与离散；
- ✓ 通过 Z 分数判断个体在总体中的相对位置；
- ✓ 支持人体工程学、产品尺寸设计、服装、家具、交通工具等人体测量应用。

局限性

- ! 样本是 CHNS 抽样样本，不等于全国总体；
- ! 年龄和性别划分非常重要；
- ! 若将不同年龄、性别、地区混在一起，可能呈偏态或混合分布；
- ! Shapiro-Wilk 对"是否存在统计显著偏离"敏感，不能单独作为模型实际意义的唯一依据；
- ! 正态分布是现实数据的近似模型，而非对现实的绝对描述。

结论

- 1 在合理划分研究总体后，人体身高数据具有接近正态分布的现实基础。
- 2 2011 年 CHNS 20 ~ 24 岁样本中，男性身高与正态模型的统计吻合程度较高；女性存在轻度统计偏离。
- 3 3σ 覆盖率显示两组样本仍与正态分布的经典概率规律保持较高一致性。
- 4 正态分布的价值在于提供一种简洁、可解释、可计算的近似模型，同时必须注意研究总体、样本代表性与统计检验方法的限制。

正态分布不是现实本身，而是理解现实数据的一种模型。

主要参考文献：[1]–[13]