

概率论与数理统计 · 课程论文

正态分布在现实数据分析中的应用

——基于中国成年人身高数据的案例分析

成 员

赵浩 (U202541916)

张璐玺 (U202541915)

汇报人:

张璐玺

为什么是身高?

01

连续型变量

身高是连续型人体测量变量，
可测量、可比较、可重复。

02

接近钟形

控制年龄与性别后，身高常呈
近似钟形，适合正态近似。

03

参数简洁

只需 μ 与 σ 两个参数，
即可刻画中心与离散。

核心问题 现实中的身高数据，到底可以在多大程度上用正态分布近似描述？

正态分布的基本理论

$$X \sim N(\mu, \sigma^2)$$

$$f(x) = \frac{1}{\sigma\sqrt{2\pi}} \exp\left[-\frac{(x-\mu)^2}{2\sigma^2}\right]$$

$$Z = \frac{X - \mu}{\sigma}$$

$$E(X) = \mu, \quad \text{Var}(X) = \sigma^2$$

3 σ 原则

理论覆盖率

$\mu \pm 1\sigma$ 68.27%



$\mu \pm 2\sigma$ 95.45%



$\mu \pm 3\sigma$ 99.73%



数据来源与研究总体

数据库

2011 CHNS

调查轮次

2011 年

年龄范围

20 ~ 24 岁

有效样本

473 人

研究总体

2011 年 CHNS 调查中年龄为 20 ~ 24 岁的成年人，按性别分别进行分析。

有效样本构成



注意：CHNS 为抽样样本，结论不能等同于“中国所有成年人”的总体规律。

样本形成与描述统计

518

原始记录



-45

身高缺失



473

有效样本



220 / 253

男 / 女

(无任何记录因超出 100 ~ 220 cm 筛选范围被删除)

男性 n = 220

171.56 ± 6.82 cm

均值 171.5614 cm 标准差 6.8218 cm

偏度 0.0107 超额峰度 -0.0150

女性 n = 253

159.59 ± 6.08 cm

均值 159.5917 cm 标准差 6.0802 cm

偏度 -0.3614 超额峰度 0.5907

直方图：实际分布长什么样




图 5-1 男性




图 5-2 女性

男性更接近正态；女性存在轻度偏离，但整体仍呈单峰钟形。

Q-Q 图与 Shapiro-Wilk 检验




图 5-3 男性 $n = 220$ • 不能拒绝正态性原假设

$W = 0.992062$ **$P = 0.2799$**

$P > 0.05$ 不等于证明正态; $P < 0.05$ 也不等于模型完全失效。




图 5-4 女性 $n = 253$ • 拒绝正态性原假设

$W = 0.987611$ **$P = 0.0281$**

3σ 原则：理论与现实有多接近

区间	理论值	男性实际	女性实际
$\mu \pm 1\sigma$	68.27%	70.00%	68.77%
$\mu \pm 2\sigma$	95.45%	95.91%	96.05%
$\mu \pm 3\sigma$	99.73%	100.00%	99.60%

女性虽在检验中被拒绝原假设，其覆盖特征仍与理论值接近；正态模型在此仍是相当好的近似。

价值与局限

价值

- 用 μ 、 σ 两个参数概括分布的中心与离散
- 标准化 Z 分数判断个体在总体中的相对位置
- 为人体工程学与产品尺寸设计提供依据
- 为区间估计与假设检验提供基础

局限

- 抽样样本不等于全国总体，外推须谨慎
- 年龄与性别划分对结论影响很大
- 不同群体混合会形成混合分布
- Shapiro-Wilk 敏感，但不能单独判定模型意义

结论

结论一 限定研究总体后，身高数据具有接近正态分布的现实基础。

结论二 男性与正态模型吻合程度较高，女性存在轻度统计偏离。

结论三 两组 3σ 覆盖率均与理论值较为接近。

结论四 正态分布是现实数据的近似模型，而非绝对描述。

正态分布不是现实本身，而是理解现实数据的一种模型。