

概率论与数理统计 · 课程论文

正态分布在现实数据分析中的应用

——基于中国成年人身高数据的案例分析

成员：赵浩 (U202541916) 、章轩睿 (U202541911)

日期：2026年9月26日

为什么研究“身高与正态分布”

- ① **连续可测** 身高是连续型人体测量变量，可测量、可比较、可重复。
- ② **近似钟形** 在控制年龄与性别后，身高常呈近似钟形，天然适合用正态模型描述。
- ③ **两参数刻画** 正态分布只需 μ 、 σ 两个参数，即可支撑标准化、区间覆盖等计算。

核心问题：现实中的身高数据，究竟在多大程度上可以用正态分布近似描述？

正态分布的基本理论

$$X \sim N(\mu, \sigma^2)$$

概率密度函数

$$f(x) = \frac{1}{\sigma\sqrt{2\pi}} \exp \left[-\frac{(x - \mu)^2}{2\sigma^2} \right]$$

$$Z = \frac{X - \mu}{\sigma}, \quad E(X) = \mu, \quad \text{Var}(X) = \sigma^2$$

标准化 Z 把任意正态分布统一为标准正态分布； μ 、 σ 即总体的平均水平与离散程度。

3 σ 原则: $\mu \pm 1\sigma \approx 68.27\%$ | $\mu \pm 2\sigma \approx 95.45\%$ | $\mu \pm 3\sigma \approx 99.73\%$

数据来源与研究总体

数据库	2011 年中国健康与营养调查 (CHNS)	2011 CHNS
调查轮次	2011 年	▼
年龄范围	20 ~ 24 岁	20 ~ 24 岁
分组方式	按性别分别分析 (男 / 女)	▼
有效样本	473 人 (男 220 / 女 253)	男 220 / 女 253

注意：CHNS 为抽样样本，结论不能等同于“中国所有成年人”的总体规律。

样本形成与描述统计



(无任何记录因超出 100 ~ 220 cm 筛选范围被删除)

指标	男性	女性
样本量 n	220	253
均值 (cm)	171.5614	159.5917
标准差 (cm)	6.8218	6.0802
偏度	0.0107	-0.3614
超额峰度	-0.0150	0.5907

直方图：实际分布长什么样

图 5-1 男性





图 5-2 女性



男性更接近正态；女性存在轻度偏离，但整体仍呈单峰钟形。

Q-Q 图与 Shapiro-Wilk 检验




图 5-3 男性 ($W=0.992062$, $P=0.2799$)
不能拒绝正态性原假设




图 5-4 女性 ($W=0.987611$, $P=0.0281$)
拒绝正态性原假设

注意: $P > 0.05$ 不等于证明正态; $P < 0.05$ 也不等于模型完全失效。

3σ 原则：理论与现实有多接近

区间	理论值	男性	女性
$\mu \pm 1\sigma$	68.27%	70.00%	68.77%
$\mu \pm 2\sigma$	95.45%	95.91%	96.05%
$\mu \pm 3\sigma$	99.73%	100.00%	99.60%

男性实际覆盖率与理论值高度一致；女性虽被拒绝原假设，但覆盖特征仍与理论值接近。

正态模型在这里仍是一个相当好的近似。

价值与局限

价值

- 用少量参数概括分布的中心与离散
- Z 分数判断个体在总体中的相对位置
- 支撑人体工程学、产品尺寸设计
- 为区间估计与假设检验提供基础

局限

- 抽样样本 $\neq$ 全国总体，外推须谨慎
- 年龄、性别划分对结果影响很大
- 不同群体混在一起会形成混合分布
- Shapiro-Wilk 敏感，但不能单独判定模型意义

结论

- ① 在限定研究总体后，身高数据具有接近正态分布的现实基础。
- ② 男性与正态模型吻合较高；女性存在轻度统计偏离。
- ③ 3σ 覆盖率显示两组仍与正态经典规律保持较高一致性。
- ④ 正态分布是简洁、可解释、可计算的近似模型，须注意总体代表性与检验限制。

正态分布不是现实本身，而是理解现实数据的一种模型。

参考文献 [1]–[13]